

Optymalizacja

1. Cel laboratorium

Celem zadania jest przedstawienie zagadnień dotyczących różnych fizycznych modeli kostek oraz projektowania agregacji.

2. Założenia wstępne

2.1. Specyfikacja bazy danych:

- Rozmiar bazy danych (Hurtowni Danych): 16 336.00 MB
- Liczba wierszy w tabeli faktów: 9 983 641

2.2. Środowisko testowe

Pomiary wykonano na Dell Inspiron 16 Plus o następującej konfiguracji:

- **Procesor:** 12 Gen Intel Core i7-12700H
- **Pamięć RAM:** 40 GB
- **Dysk:** 1 TB
- **System operacyjny:** Windows 11
- **Oprogramowanie:** SQL Server Management Studio, SQL Server Profiler, Visual Studio 2022.

Podczas pomiarów jedynymi aktywnymi aplikacjami były SSMS, przeglądarka internetowa, SQL Server Profiler oraz Visual Studio 2022.

3. Założenia teoretyczne

	MOLAP	HOLAP	ROLAP
Czas odpytywania	Krótki	Umiarkowany (krótki przy dobrze zaprojektowanych agregacjach)	Długi
Czas przetwarzania	Długi	Umiarkowany	Krótki
Rozmiar całkowity	Duży	Umiarkowany	Mały

4. Testowanie

Pomiary wykonano dla trzech scenariuszy zapytań o różnym stopniu złożoności:

4.1. Krótki opis zapytań:

1. [Daty]

```
SELECT
  { [Measures].[Rezerwacja F Count], [Measures].[Średnia Cena Turnusu] } ON
COLUMNS,
  { [Data D].[Dzien].&[2021]&[3]&[1] : [Data D].[Dzien].&[2021]&[3]&[31] } ON
ROWS
FROM [Warehouse Travel Agency]
```

2. [Konkretny atrybut wymiaru]

```
SELECT
  [Measures].[Rezerwacja F Count] ON COLUMNS,
  TOPCOUNT(
    NONEMPTY(
      [Wycieczka D].[Destynacja].[Destynacja].Members,
      [Measures].[Rezerwacja F Count]
    ),
    10,
    [Measures].[Rezerwacja F Count]
  ) ON ROWS
FROM [Warehouse Travel Agency]
```

3. [Ogólne]

```
SELECT
  [Measures].[Średnia Cena Turnusu] ON COLUMNS,
  [Wycieczka D].[Nazwa Wycieczki].[Nazwa Wycieczki].Members ON ROWS
FROM [Warehouse Travel Agency]
WHERE ([Junk D].[Status Opłacenia].&[Tak], [Data D].[Miesiac].&[2017]&[10])
```

4.2. Wyniki pomiarów

Po odrzuceniu wartości odstających (outliers), uzyskano następujące wyniki zbiorcze

Bez agregacji

Tabela 4.1 Porównanie czasów procesowania i zapytań [ms] bez agregacji

Procesowanie kostki		Zapytanie 1		Zapytanie 2		Zapytanie 3	
MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
55136	985	311	701	137	1737	110	453
54783	938	322	718	133	1779	95	453
54766	905	321	691	141	1723	107	451
54171	908	297	712	134	1764	93	443
55700	941	312	692	131	1708	91	445
54158	944	321	682	125	1765	109	443
55140	900	336	719	129	1765	104	455
54051	953	321	707	139	1738	110	452
55863	922	298	699	132	1766	103	444
54633	907	325	715	126	1747	98	452

Z agregacją

Tabela 4.2 Porównanie czasów procesowania i zapytań [ms] z agregacją

Procesowanie kostki		Zapytanie 1		Zapytanie 2		Zapytanie 3	
MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
138793	85188	286	685	31	1661	93	452
137461	83390	283	687	10	1673	96	440
136773	83321	269	655	10	1687	93	455
135478	83412	283	705	16	1695	93	423
137390	83505	284	686	10	1681	94	448
135976	83195	269	701	9	1672	99	438
136873	83358	297	706	16	1689	99	438
138749	83440	281	683	10	1692	94	428
135703	83214	285	711	12	1688	94	432
1378854	83377	275	644	20	1699	95	439

Tabela 4.3 Średnia i odchylenie standardowe czasu przetwarzania kostki [ms] oraz zapytań dla MOLAP i ROLAP bez agregacji.

	Procesowanie kostki		Zapytanie 1		Zapytanie 2		Zapytanie 3	
Z agregacją	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
Średnia	54840.1	930.3	316.4	703.6	132.7	1749.2	102.0	449.1
OS	628.1	26.9	12.1	12.7	5.3	22.5	7.3	4.8

Tabela 4.4 Średnia i odchylenie standardowe czasu przetwarzania kostki [ms] oraz zapytań dla MOLAP i ROLAP z agregacją.

	Procesowanie kostki		Zapytanie 1		Zapytanie 2		Zapytanie 3	
Z agregacją	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP	MOLAP	ROLAP
Średnia	261205.0	83540.0	281.2	686.3	14.41	1683.7	95.0	439.3
OS	1172.5	586.8	8.4	22.0	6.9	11.8	2.3	10.1

5. Ustawienia pamięci podręcznej i agregacji

Podczas testów zadbano o wiarygodność wyników poprzez każdorazowe czyszczenie pamięci podręcznej (cache) serwera SSAS za pomocą skryptu XMLA .

```
<Batch xmlns="http://schemas.microsoft.com/analysiservices/2003/engine">
  <ClearCache>
    <Object>
      <DatabaseID>HD_warehouse</DatabaseID>
    </Object>
  </ClearCache>
</Batch>
```

Agregacje zostały zrobione atrybutach: dzien, status_opłacenia, destynacja, nazwa_wycieczki.

6. Dyskusja

6.1 Porównanie modeli MOLAP i ROLAP (bez agregacji)

Czas zapytań

Zgodnie z teorią , model MOLAP wykazał się znacznie krótszym czasem odpowiedzi na zapytania niż ROLAP. Przykładowo, dla Zapytania 2 średni czas w MOLAP wyniósł ok. 132.7 ms, podczas gdy w ROLAP aż 1749.2 ms. Wynika to z faktu, że MOLAP przechowuje dane w zoptymalizowanych strukturach wielowymiarowych, a ROLAP musi każdorazowo odpytywać relacyjną bazę danych.

Czas przetwarzania (Process)

W tym przypadku przewagę zyskał model ROLAP, którego czas procesowania (ok. 930 ms) był dużo krótszy w porównaniu do MOLAP (ok. 54 840 ms). Potwierdza to założenie, że ROLAP nie wymaga czasochłonnego budowania struktur wielowymiarowych.

6.2 Wpływ agregacji na wydajność

Wydajność zapytań

Wprowadzenie agregacji (na wymiarach: dzień, status opłacenia, destynacja, nazwa wycieczki) przyniosło oczekiwaną poprawę wydajności. Najbardziej zauważalny spadek czasu odpowiedzi pojawił się w Zapytaniu 2 dla modelu MOLAP - z poziomu ok. 132 ms do zaledwie ok. 14,4 ms. W modelu ROLAP agregacje również skróciły czas zapytań (np. z 1749 ms do 1683 ms), ale różnica ta była mniej odczuwalna niż w MOLAP.

Koszt przetwarzania

Ceną za szybsze zapytania jest wydłużony czas procesowania kostki. Po dodaniu agregacji, czas przetwarzania dla MOLAP wzrósł drastycznie z ok. 54 sekund do ok. 261 sekund. W modelu ROLAP czas ten wzrósł z ok. 0,9 sekundy do ok. 83 sekund, co wynika z konieczności wyliczenia i zapisania zdefiniowanych agregatów.

6.3 Wnioski

Przeprowadzone badanie pozwoliło zweryfikować jak wybór modelu przechowywania danych oraz struktury agregacji wpływa na wydajność hurtowni danych. Wyniki eksperymentów w pełni potwierdziły założenia teoretyczne: model MOLAP oferuje najwyższą szybkość odpytywania, natomiast ROLAP charakteryzuje się najkrótszym czasem przetwarzania. Zastosowanie agregacji okazało się skutecznym narzędziem optymalizacji zapytań, choć wiązało się z wyraźnym wzrostem kosztów procesowania kostki, co jest widoczne w wynikach średnich dla obu modeli. Reasumując, dobór odpowiedniego modelu i stopnia agregacji powinien być podyktowany specyficznymi wymaganiami systemu w zakresie częstotliwości aktualizacji danych oraz oczekiwanego czasu reakcji na zapytania użytkowników.